

UNIVERSIDADE ESTADUAL DE CAMPINAS  
Faculdade de Engenharia Elétrica e de Computação

**Adriano José Ferruzzi**

SISTEMA DE SUPORTE MÉDICO PARA AUXILIAR NO  
DIAGNÓSTICO DE MELANOMA

Campinas  
2023

# Resumo

O câncer de pele é a neoplasia de maior incidência no Brasil, sendo o melanoma um dos tipos. Seu diagnóstico precoce é crucial para garantir um tratamento eficaz e possibilitar a diminuição da mortalidade relacionada à doença. Neste contexto, o presente trabalho explora como as redes neurais convolucionais (CNNs) podem ser utilizadas para melhorar a precisão e eficiência na detecção de melanoma, bem como os desafios e limitações atuais do uso dessa abordagem. Para isso, o estudo realizou uma revisão de literatura e levantamento bibliográfico, apresentando as técnicas, as limitações encontradas e uma proposta de sistema para auxiliar em diagnósticos.

# Sumário

<b>1. Introdução</b>	<b>4</b>
1.1. Objetivos	5
1.2. Metodologia	5
<b>2. Trabalhos Relacionados</b>	<b>8</b>
2.1. Deep Learning and Machine Learning Techniques of Diagnosis Dermoscopy Images for Early Detection of Skin Diseases	8
2.2. Melanoma recognition by a deep learning convolutional neural network - Performance in different melanoma subtypes and localisations	9
2.3. Skin Cancer Classification Using Convolutional Neural Networks: Systematic Review.	10
2.4. A deep convolutional neural network for COVID-19 detection using chest X-rays	10
2.5. Demais estudos relacionados	11
<b>3. Resultados</b>	<b>13</b>
3.1. Avaliação do Algoritmo	13
3.2. Protótipo de Sistema	15
<b>Conclusão</b>	<b>17</b>
<b>Referências Bibliográficas</b>	<b>18</b>

# 1.Introdução

O câncer de pele é a neoplasia de maior incidência no Brasil, sendo o melanoma um dos tipos. O melanoma é o tipo de câncer de pele menos frequente e o mais grave, detectado em 4% dos pacientes; nas fases iniciais é curável, mas, sem tratamento, pode implicar no surgimento de metástases que causam elevada mortalidade (BOMFIM; GIOTTO; SILVA, 2018). Nesse sentido, o diagnóstico precoce é crucial para garantir um tratamento eficaz e possibilitar a diminuição da mortalidade relacionada à doença.

Segundo Argenziano e Soyer (apud BRINKER et al., 2018), os dermatologistas têm uma taxa de precisão de 65% a 80% no diagnóstico de melanoma, sem utilizar nenhuma ferramenta de suporte adicional, chegando a 84% quando é utilizada a combinação de inspeção visual e imagens dermatoscópicas.

Nesse sentido, para auxiliar nesse diagnóstico precoce, o avanço de tecnologias, como as redes neurais, surgem com a possibilidade de auxiliar os diagnósticos médicos, pois é possível pensar em ferramentas de suporte médico que ajudam a melhorar a eficiência da detecção de melanomas.

As redes neurais convolucionais (CNNs) apresentam uma abordagem interessante para a classificação e na detecção automática de melanomas, pois trabalham com análise de imagens e são capazes de extrair as características mais básicas da imagem passada, como bordas, linhas, cores entre outras coisas. Elas podem identificar rostos, objetos e sinais de trânsito melhor do que os humanos e, portanto, podem ser encontradas em robôs e carros autônomos (LeCun, Bengio e Hinton, apud BRINKER et al., 2018).

Sendo assim, o presente trabalho explora como as CNNs podem ser utilizadas para melhorar a precisão e eficiência na detecção de melanoma, bem como os desafios e limitações atuais do uso dessa abordagem.

O estudo será desenvolvido com preceitos na literatura, pesquisa bibliográfica e estudo de casos reais. Para atingir tal propósito o trabalho está dividido em cinco partes, em que a primeira se trata deste preâmbulo que apresenta a justificativa da temática, objetivos e metodologia.

O segundo capítulo apresenta alguns trabalhos relacionados a respeito do uso de CNNs na detecção de melanoma. O capítulo seguinte apresenta a metodologia utilizada, incluindo a descrição das bibliotecas utilizadas na arquitetura. O penúltimo capítulo apresenta uma avaliação dos resultados obtidos. Finalmente, o último capítulo

apresenta as conclusões, limitações e perspectivas futuras para o uso de CNNs na detecção de melanoma.

## 1.1. Objetivos

Este trabalho tem como objetivo apresentar uma estratégia para a criação de um modelo de rede neural treinada para classificar os melanomas entre benigno e maligno. Após o desenvolvimento e apresentação do modelo, será apresentada uma proposta de sistema que permite a classificação de um melanoma a partir do upload de uma imagem feita pelo médico. Dessa forma, pretende-se criar uma solução que possa auxiliar os médicos em suas decisões clínicas.

## 1.2. Metodologia

Este estudo foi pautado em uma pesquisa teórica e prática, feita por meio de uma revisão de literatura e levantamento bibliográfico de natureza qualitativa. Ele foi realizado com base em artigos publicados e já revisados por pares nos últimos 6 anos, ou seja, de 2017 a 2023, nas bases de dados da ScienceDirect Journals, PubMed, PubMed Central, Science Citation Index Expanded (Web of Science), Science Citation Index Expanded e Google Acadêmico.

A respeito da seleção dos artigos, foram utilizadas as seguintes palavras-chave no portal Periódicos Capes: melanoma, neural networks, machine learning. Para o desenvolvimento deste estudo foram selecionados 3 artigos, dos 293 identificados pelas buscas. Sobre os critérios de inclusão, foram utilizados artigos nos idiomas de português e inglês relacionados ao tema, compreendidos na faixa temporal estipulada e que tiveram proximidade com o contexto deste estudo. Em relação aos critérios de exclusão, foram desconsiderados os artigos que não estavam nos idiomas determinados, fora da faixa de tempo estabelecida e que não traziam a temática base para esta pesquisa.

Além dos artigos que tratam a respeito de análise de melanomas, também foram incluídos dois artigos que tratam da classificação de radiografias de pulmão para detecção de COVID-19. Embora o tema desses artigos não seja melanoma, as

técnicas utilizadas para a criação das redes neurais foram muito úteis para o desenvolvimento deste trabalho.

A base de dados *ISIC Archive* foi utilizada para a construção do *dataset* de imagens de melanoma. Nela, foram selecionadas as imagens a serem utilizadas no treinamento e teste do modelo de rede neural. Trata-se da *Database - The International Skin Imaging Collaboration (ISIC archive)*, um projeto que tem como objetivo avançar a pesquisa de melanoma. Ele apresenta uma galeria que permite explorar coleções de conjuntos de dados de imagem de alta qualidade (“Skin Cancer Images”, [s.d.]).

Nessa base de dados também estão armazenados os metadados de cada imagem, que inclui o diagnóstico da mancha. Entretanto, para fins de desenvolvimento da aplicação foi levado em consideração apenas se o melanoma é benigno ou maligno.

O armazenamento das imagens selecionadas foi dividido em duas pastas no *Google Drive*. Na pasta “0” estão armazenadas as imagens com melanomas benignos e na pasta “1” estão armazenadas as imagens com melanomas malignos. Além disso, para garantir que os valores das pastas não gerassem pesos na classificação das imagens, foi utilizada a técnica *One Hot Encoding* para criar variáveis do tipo *Dummy*, que garante a categorização dos dados de forma distinta sem dar pesos.

Para a construção e treinamento das redes neurais foi utilizado o *Google Colab*. Essa plataforma foi escolhida, pois fornece uma interface *Jupyter Notebook* gratuita. A interface tem como *backend* uma máquina virtual que trabalha como nó computacional com 2 núcleos Intel Xeon de 2.20GHz, 12 GB de memória RAM e 1 GPU Tesla T4 com 15 GB de memória interna. Essa plataforma dá suporte a bibliotecas como o *Opencv*, para trabalhar com o redimensionamento das imagens, além das bibliotecas *Tensor Flow* e *Keras*, utilizadas no desenvolvimento da rede neural.

Durante o desenvolvimento a rede convolucional foi dividida em duas etapas: A primeira é relacionada ao processamento da imagem e a segunda trabalha como uma rede neural tradicional, usando os *pixels* como entrada, em seguida ele faz a aplicação nas camadas ocultas e no final exibe a resposta.

As redes neurais convolucionais criadas servem para extrair características mais básicas da imagem passada, como bordas, linhas, cores entre outras coisas. Em seguida, as camadas de convolução fazem a extração dessas características. Neste trabalho foram utilizadas 2 camadas de convolução, mas é possível utilizar dezenas, a depender da complexidade do que se espera atingir.

Além disso, foi utilizado o modelo pré-treinado chamado *ResNet (Residual Neural Network)* treinada com a base de dados “*imagenet*”. Esse modelo foi utilizado com objetivo de extrair informações relevantes de diferentes imagens utilizando modelos de aprendizado de máquina já treinados (HE et al., 2016).

Uma vez carregada as imagens, o *Average Pooling 2D* pega a média do tamanho delas para fazer o redimensionamento. Em seguida, é feita a conversão da matriz para vetor, para realizar o *input* dos *pixels*. Dessa forma, é criada a camada de entrada da rede neural.

Por sua vez, a camada densa da rede neural foi criada com 256 neurônios e com a função de ativação ReLU (unidade linear retificada), que é a função de ativação mais amplamente utilizada ao projetar redes neurais. A principal vantagem de usar essa função sobre outras funções de ativação é que ela não ativa todos os neurônios ao mesmo tempo. Para evitar o *overfitting* foi criado uma camada *dropout*, excluindo 20% dos neurônios, enquanto os neurônios restantes são ativados em cada iteração.

Na saída foram criados dois neurônios para fazer a classificação. Como função de ativação, foi utilizado o “sigmoid”, pois a saída é somente 1 ou 0. Outra alternativa é a função “softmax” caso a classificação resultasse em mais de duas saídas, conforme explicado pela Data Science Academy, “A função softmax é idealmente usada na camada de saída do classificador, onde realmente estamos tentando gerar as probabilidades para definir a classe de cada entrada.” (DSA, 2022). A Figura 1 ilustra a arquitetura da rede neural convolucional criada.

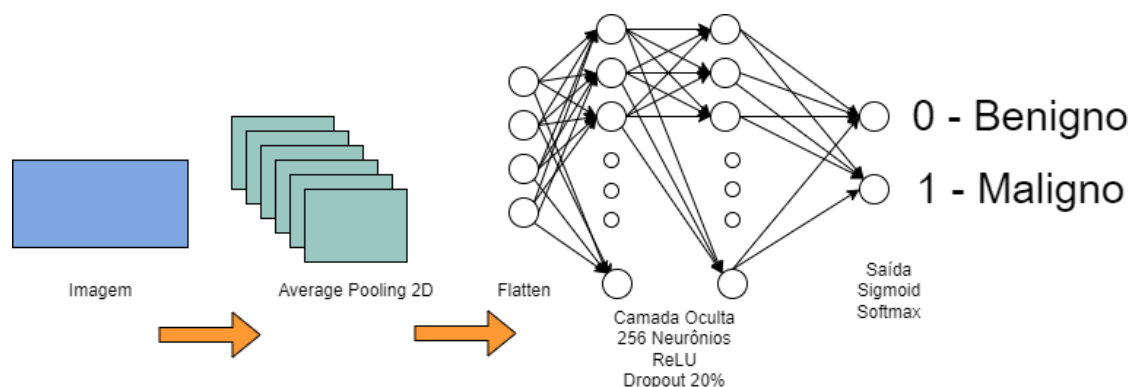


Figura 1 - Arquitetura da rede neural convolucional.

Por fim, o treinamento foi feito com 1000 imagens de melanoma benigno e 1000 imagens de melanoma maligno. Os testes, com 200 imagens de melanoma benigno e 200 imagens de melanoma maligno.

## 2.Trabalhos Relacionados

### 2.1. Deep Learning and Machine Learning Techniques of Diagnosis Dermoscopy Images for Early Detection of Skin Diseases

Neste artigo, o autor usa várias técnicas de redes neurais para fazer a classificação de imagens de melanoma entre benigno e maligno. Para isso, eles utilizam técnicas de redes neurais artificiais, redes neurais convolucionais e rede neural direta (*Feedforward neural network*). Além de fazer o tratamento das imagens para que possam ser melhor analisadas pelo algoritmo. Os sistemas propostos foram aplicados a dois conjuntos de dados: ISIC 2018 e PH2 (ABUNADI; SENAN, 2021).

Na etapa de pré-processamento são utilizadas duas técnicas para aprimorar as imagens, o filtro laplaciano e o método de depilação das imagens. A técnica de filtro utilizada é o filtro laplaciano é um filtro para detecção de arestas. Este filtro detecta as áreas de mudança na imagem (por exemplo, bordas de lesões de pele). A técnica de depilação é uma tecnologia de pré-processamento que remove os pelos da área da lesão, chamada Dull Razor, ela é uma técnica importante na melhoria do código, pois a presença de cabelo na área da lesão causa confusão no algoritmo (ABUNADI; SENAN, 2021).

Após essa etapa é feito um tratamento para isolar pedaços de pele com lesão e pedaços saudáveis. Para isso, o autor utiliza um algoritmo de segmentação de imagem.

Depois do pré-processamento é feita a extração de recursos, em que são combinados três métodos de extração, os algoritmos LBP (*Local Binary Patterns*), GLCM (*Gray Level Co-occurrence Matrix*) e DWT (*Discrete Wavelet Transform*), para extrair as características mais críticas das lesões de pele das imagens. Esses algoritmos têm o objetivo de tratar os pixels e encontrar a textura da área de interesse para identificar se é lisa ou rugosa e marcar os pixels encontrados.

Como resultado, os autores compararam as redes neurais tradicionais (ANN e FFNN) com as redes CNN (ResNet-50 e AlexNet). Nessa etapa, foi observado que os algoritmos ANN e FFNN tiveram melhor desempenho do que dois modelos CNN, ResNet-50 e AlexNet. Apesar de aplicar muitas técnicas de otimização e extrair as características por métodos híbridos entre três algoritmos, existem algumas limitações e desafios encontrados no estudo, que são representados na semelhança significativa



entre as características de algumas doenças, o que causa confusão para os algoritmos de classificação no momento de fazer um diagnóstico.

## 2.2. Melanoma recognition by a deep learning convolutional neural network - Performance in different melanoma subtypes and localisations

Este artigo avalia, utilizando análise estatística, o desempenho de redes neurais convolucionais (CNNs) para o diagnóstico de melanoma, considerando a localização, espessura e subtipo (WINKLER et al., 2020).

Para realizar o estudo, utilizou-se uma rede neural que já está em uso no mercado, a versão mais atual da CNN *Mole Analyzer-Pro®*; *FotoFinder Systems GmbH, Bad Birnbach, Germany*, trata-se de um dispositivo médico aprovado pelo mercado europeu. O objetivo é avaliar a ferramenta e apresentar dados de sensibilidade, especificidade e curva ROC.

Para o estudo, foram compilados seis conjuntos de imagens dermatoscópicas (set-SSM, set-LMM, set-NM, set-Mucosa, set-AM pele e set-AM unha). As imagens dermatoscópicas de melanomas para os seis conjuntos diferentes foram selecionadas aleatoriamente de bibliotecas de imagens e categorizadas por localização ou subtipos.

O estudo revelou algumas limitações, como o uso de imagens dermatoscópicas de conjuntos de teste foram selecionadas aleatoriamente de bibliotecas de imagens locais de diferentes instituições, o que não garante uma amostra representativa como encontrada em estudos de base populacional.

A alta qualidade das imagens utilizadas, pois em um ambiente de rotina clínica, uma qualidade inferior pode resultar em um desempenho de diagnóstico reduzido. Outro desafio é o fato de que a maioria das imagens foi derivada de pacientes de pele clara, de modo que nenhuma conclusão sobre lesões de indivíduos de outras origens étnicas pode ser tirada.

Os resultados mostram que é razoável supor que as CNNs podem ajudar a contrabalançar baixas precisões humanas inerentes a melanomas nodulares e melanomas de pele acral. Por outro lado, atualmente os autores desencorajam a aplicação da CNNs em lesões mucosas e subungueais.

## 2.3. Skin Cancer Classification Using Convolutional Neural Networks: Systematic Review.

O estudo apresenta uma revisão sistemática da pesquisa de ponta sobre a classificação de lesões cutâneas com redes neurais convolucionais (CNNs). Ele limita a revisão aos classificadores de lesões cutâneas (BRINKER et al., 2018).

Para o levantamento de dados, o estudo usou os bancos de dados *Google Scholar*, *PubMed*, *Medline*, *ScienceDirect* e *Web of Science* foram pesquisados em busca de revisões sistemáticas e artigos de pesquisa originais publicados em inglês. Os termos de pesquisa foram redes neurais convolucionais, aprendizado profundo, câncer de pele, lesões, melanoma e carcinoma foram combinados.

Entre as principais descobertas está a diferença dos métodos utilizados para fazer a classificação, além dos dados utilizados nos treinamentos, pois alguns trabalhos usam arquivos de imagens não públicas, tornando ainda mais difícil reproduzir os resultados.

Outra observação foi que as imagens do banco de dados ISIC, por exemplo, vêm principalmente dos Estados Unidos, Europa e Austrália e para obter uma classificação precisa também para pessoas de pele escura, a CNN deve aprender a abstrair da cor da pele. No entanto, isso só pode ocorrer se observar fotos suficientes de pessoas de pele escura durante o treinamento.

Como resultado, o estudo concluiu que as CNNs apresentam alto desempenho como classificadores de lesões de pele de última geração. Entretanto, é difícil comparar diferentes métodos de classificação devido às abordagens usarem conjuntos de dados não públicos para treinamento e/ou testes, dificultando a reprodutibilidade.

## 2.4. A deep convolutional neural network for COVID-19 detection using chest X-rays

Neste estudo, os autores utilizam as redes neurais pré-treinadas no ImageNet e aplicam uma abordagem de aprendizado de transferência dupla, usando o conjunto de dados NIH ChestX-ray14 como uma etapa intermediária. O objetivo deles foi classificar imagens baseadas em redes convolucionais densas e aprendizado de transferência para classificar imagens de radiografia de tórax. Além disso, eles introduziram uma novidade chamada manutenção de neurônios de saída, que altera a

técnica de aprendizado de transferência dupla. Além de utilizar a técnica de mapa de calor, que pode auxiliar muito na detecção de COVID-19 ((BASSI; ATTUX, 2022)).

Estudos desse tipo são de grande importância, pois a outra forma de confirmar se o paciente está com COVID-19 é via exame RT-PCR. Este exame possui uma alta especificidade, mas também é caro e lento, ao passo que as radiografias são mais rápidas e baratas.

Durante as avaliações eles apresentam uma excelente precisão com o modelo treinado, que torna o algoritmo uma boa opção para a identificação de pacientes com COVID.

Embora este estudo não esteja focado no tema de detecção de melanoma, ele pode ser muito útil devido às explicações e formas de tratamento de imagem e construção da rede neural. O trabalho em si utiliza a biblioteca PyTorch pré-treinada do ImageNet do DenseNet201. No presente trabalho é utilizado o Tensorflow, entretanto, as ideias e formas de construção da rede neural e avaliações foram muito úteis para a construção do algoritmo deste trabalho.

Por fim, o método apresentado no trabalho superou o uso exclusivo de aprendizado de transferência dupla e aprendizado de transferência simples nas redes densas de 201 camadas, levando a ótimos resultados.

## 2.5. Demais estudos relacionados

Além dos artigos já apresentados, também foram selecionados dois artigos que apresentam técnicas de aprendizado de máquina utilizando redes neurais convolucionais. Esses artigos foram importantes para indicar o caminho a ser feito neste trabalho.

O primeiro artigo trata de COVID-19 e pesquisa modelos automatizados para realizar classificação e segmentação de imagens médicas de pacientes com COVID-19. O estudo apresenta três desafios: fazer o diagnóstico de COVID-19 através do raio-X, fazer o diagnóstico de COVID-19 através de imagens de tomografia e segmentar a opacidade do pulmão. Para resolver a classificação das imagens, os autores utilizaram redes neurais convolucionais. Um outro desafio apresentado no estudo foi o fato das imagens não estarem rotuladas, o que dificulta a montagem do algoritmo para o treinamento (CARMO et al., 2021).

O segundo traz uma revisão de métodos de classificação para análise computadorizada de tomografia (CARMO et al., 2022). Essa revisão busca responder o seguinte questionamento: Quais são os métodos de segmentação avaliados

quantitativamente, computadorizados e automatizados para o pulmão e seus lóbulos, usando imagens de tomografia computadorizada?

O estudo apresenta sete categorias para classificar os métodos durante a fase de extração. *Thresholding-based Methods*, *Region-based Methods*, *Shape or Model-based Methods*, *Neighboring Anatomy-guided Methods* e *Machine Learning-based Methods*, além de *Traditional Machine Learning* e *Deep Learning*.

### 3.Resultados

Neste capítulo, serão apresentados a avaliação do algoritmo e a proposta de sistema que utiliza o modelo treinado.

#### 3.1. Avaliação do Algoritmo

O parâmetro de métrica utilizado para gerar a análise foi o “*accuracy*” que apresenta as métricas de erro e taxa de acerto. Ao analisar a Figura 2, percebe-se que a taxa de acerto aumenta conforme os pesos são ajustados em cada “*epoch*”. Neste trabalho, os pesos foram ajustados 25 vezes. Ao final do treinamento o “*accuracy*” parou em 99,35%.

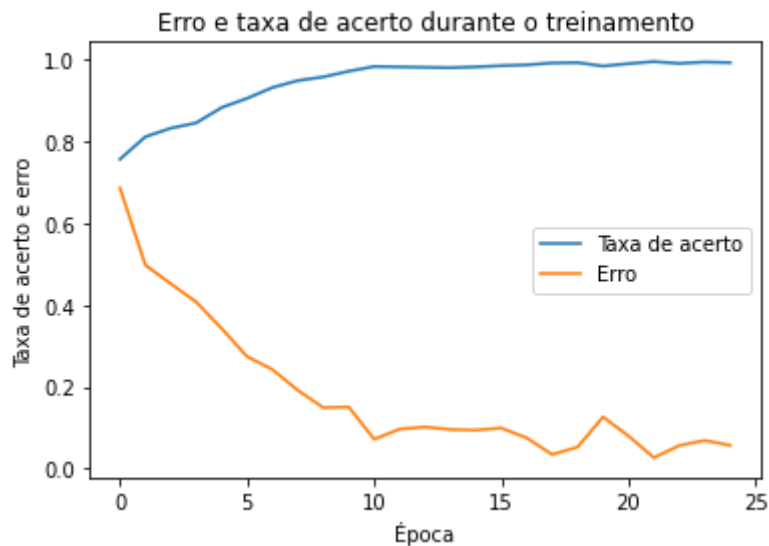


Figura 2 - Gráfico de Taxa de Acerto e Erro.

Ao testar o modelo com a função *evaluate\_generator()* do Tensor Flow o resultado foi de 91% da base de dados de teste. Trata-se de um valor interessante, uma vez que a rede neural foi treinada com poucas “*epochs*”.

Além disso, foram criadas duas listas para armazenar os valores originais e as previsões para que ambas fossem comparadas com a função *accuracy\_score()*. Ao comparar as duas listas, a acurácia ficou em 71,75%.

Por sua vez, a Figura 3 apresenta a matriz de confusão com os valores originais no eixo y e as previsões no eixo x. Conforme pode ser observado na matriz de confusão, o algoritmo precisa ser melhor treinado para prever melanomas malignos, pois ele fez a previsão de 100 imagens como benigno, em que o correto

seria maligno. Ao mesmo tempo que ele fez a previsão de 190 imagens, de forma correta, como benigno. Quando se observa o melanoma maligno, percebe-se que o algoritmo obteve apenas 8 falsos positivos e que fez a previsão correta de 95 imagens.




Figura 3 - Matriz de confusão dos resultados de previsão em comparação com os valores reais.

Em seguida, ao analisar o *classification report*, comparando os valores originais e os previstos, pode-se observar que a acurácia está em 72%, assim como apresentado no *accuracy\_score()*. O *F1 score* apresenta 0.70, lembrando que neste projeto os dados não estão desbalanceados, pois foram utilizadas 1000 imagens de cada classe para fazer o treinamento da rede neural. Os dados coletados pela função *classification\_report()* podem ser vistos na Figura 4.

	precision	recall	f1-score	support
0	0.65	0.96	0.77	200
1	0.92	0.47	0.63	200
accuracy			0.72	400
macro avg	0.78	0.72	0.70	400
weighted avg	0.78	0.72	0.70	400

Figura 4 - Avaliação do algoritmo.

Ao interpretar os resultados de *precision* e *recall* de cada classe, é possível verificar que na classe 0, que representa o melanoma benigno, o *recall* está com 0.96, isso indica que o modelo identifica corretamente 96% das imagens com melanoma

benigno e ao prever que uma imagem é benigna ele está certo em 65% das vezes, conforme observado no *precision*.

No caso da classe 1, que representa o melanoma maligno, observa-se o *recall* com 0.47, indicando que o modelo identifica corretamente apenas 47% das imagens com melanoma maligno, entretanto quando o algoritmo classifica uma imagem como maligna ele está certo em 92% das vezes, conforme observado na coluna *precision*.

Finalmente, os resultados indicam que o algoritmo está funcionando de maneira correta, mas que pode ser melhorado, principalmente quando se refere a identificação de melanomas malignos.


## 3.2. Protótipo de Sistema

Um dos principais desafios é disponibilizar o modelo treinado, sendo assim, após ter o modelo treinado, foi criado um *software* que disponibiliza o classificador de uma maneira simples, permitindo que o médico utilize o modelo de classificação de melanoma em suas decisões clínicas.

Para isso, foi desenvolvido um outro código que serve como um produto mínimo viável, cujo objetivo é carregar o modelo treinado e permitir que um usuário faça o *upload* de uma foto de uma mancha ou pinta para que o sistema classifique como benigno ou maligno. A Figura 5 apresenta uma parte do código que serve como uma proposta de um sistema que possibilita o *upload* e classificação de uma imagem.

Todo o sistema foi criado utilizando o *Google Colab* também e ambos estão armazenados no *github* para consulta através do link: <https://github.com/adrianoferruzzi/SistemaMelanoma>

```
# Redimensionando a imagem
img = cv2.resize(img, (256, 256))
cv2_imshow(img)
img = img / 255
img = img.reshape(-1, 256, 256, 3)
```



```
[7] predict = model_loaded(img)
    predict

<tf.Tensor: shape=(1, 2), dtype=float32, numpy=array([[1., 0.]], dtype=float32)>
```

```
[8] # Classificação da imagem
    # 0 = Benigno
    # 1 = Maligno
    predict2 = np.argmax(predict)
    predict2

0
```

Figura 5 - Proposta de código para o sistema.



# Conclusão

Conclui-se que o objetivo do presente trabalho foi atingido, uma vez que apresentou-se uma estratégia para a criação de um modelo de rede neural capaz de fazer a classificação de melanomas, entre benigno e maligno, e disponibilizar o modelo para uso em um sistema mínimo viável. Os artigos científicos para a construção do presente estudo foram valiosos para a obtenção do objetivo proposto inicialmente, sobretudo devido a abordagens similares.

Contudo, existem limitações que foram encontradas, uma delas é a possibilidade do modelo não refletir as necessidades do povo brasileiro, uma vez que a base de dados apresenta grande parte de imagens de pessoas brancas, dificultando o treinamento para a previsão nas demais etnias existentes no Brasil. Outra limitação é o tratamento das imagens, pois não foi utilizado o filtro Laplaciano, por exemplo.

Além disso, o modelo não tem uma porcentagem de identificação satisfatória quando o melanoma é maligno, sendo necessário um melhor tratamento de imagens e mais treinamento do modelo para que o sistema possa ser disponibilizado em produção.

A partir dessas tratativas, conclui-se que as estratégias utilizadas no desenvolvimento do projeto estão corretas, embora necessite de mais tempo de treinamento e refino no uso das imagens. Para pesquisas futuras, pode-se utilizar outras técnicas de aprendizado de máquina, melhorar o tratamento das imagens e comparar os resultados com as diferenças e melhorias.

Finalmente, o trabalho apresenta um modelo que faz a classificação de imagens de melanoma, além de mostrar uma possível implementação de sistema auxiliar de suporte a diagnóstico médico.

## Referências Bibliográficas

- ABUNADI, I.; SENAN, E. M. Deep Learning and Machine Learning Techniques of Diagnosis Dermoscopy Images for Early Detection of Skin Diseases. **Electronics**, v. 10, n. 24, p. 3158, jan. 2021.
- BASSI, P. R. A. S.; ATTUX, R. A deep convolutional neural network for COVID-19 detection using chest X-rays. **Research on Biomedical Engineering**, v. 38, n. 1, p. 139–148, 1 mar. 2022.
- BOMFIM, S. S.; GIOTTO, A. C.; SILVA, A. G. E. Câncer de pele: conhecendo e prevenindo a população. **Revista de Divulgação Científica Sena Aires**, v. 7, n. 3, p. 255–259, 2018.
- BRINKER, T. J. et al. Skin Cancer Classification Using Convolutional Neural Networks: Systematic Review. **Journal of Medical Internet Research**, v. 20, n. 10, p. e11936, 17 out. 2018.
- CARMO, D. et al. Rapidly deploying a COVID-19 decision support system in one of the largest Brazilian hospitals. **Health Informatics Journal**, v. 27, n. 3, p. 14604582211033016, 1 jul. 2021.
- CARMO, D. et al. A Systematic Review of Automated Segmentation Methods and Public Datasets for the Lung and its Lobes and Findings on Computed Tomography Images. **Yearbook of Medical Informatics**, v. 31, n. 1, p. 277–295, ago. 2022.
- DSA, E. **Capítulo 8 - Função de Ativação**. Disponível em: <<https://www.deeplearningbook.com.br/funcao-de-ativacao/>>. Acesso em: 7 fev. 2023.
- HE, K. et al. **Deep Residual Learning for Image Recognition**. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). **Anais...** Em: 2016 IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR). jun. 2016.
- Skin Cancer Images. Cancer Center.ai - AI in Oncology and Pathology**, [s.d.]. Disponível em: <<https://cancercenter.ai/database/skin-cancer-images/>>. Acesso em: 7 fev. 2023
- WINKLER, J. K. et al. Melanoma recognition by a deep learning convolutional neural network—Performance in different melanoma subtypes and localisations. **European Journal of Cancer**, v. 127, p. 21–29, 1 mar. 2020.

## Referências Complementares

- Rotemberg, V., Kurtansky, N., Betz-Stablein, B. et al. **A patient-centric dataset of images and metadata for identifying melanomas using clinical context**. Sci Data 8, 34 (2021). <https://doi.org/10.1038/s41597-021-00815-z>  
<https://www.nature.com/articles/s41597-021-00815-z#Sec14>
- Lucas Venezian Povoá, Uriel Cairê Balan Calvi, Ana Carolina Lorena, Carlos Henrique Costa Ribeiro, Israel Tojal Da Silva. **A Multi-Learning Training Approach for Distinguishing Low and High Risk Cancer Patients**. DOI: 10.1109/ACCESS.2021.3104820

## Bases de Dados de Melanoma

### **Skin Cancer Images**

<https://cancercenter.ai/database/skin-cancer-images/>

### **Database - The International Skin Imaging Collaboration (ISIC archive)**

[https://www.isic-archive.com/#!/topWithHeader/onlyHeaderTop/gallery?filter=%5B%22benign\\_malignant%7Cmalignant%22%5D](https://www.isic-archive.com/#!/topWithHeader/onlyHeaderTop/gallery?filter=%5B%22benign_malignant%7Cmalignant%22%5D)

### **API - ISIC Archive**

<https://api.isic-archive.com/api/docs/swagger/>

## Aulas Assistidas

Professoras Letícia e Paula e professor André - **Curso: Ciência e Visualização de Dados em Saúde 2022**

[https://www.youtube.com/playlist?list=PL3JRjVnXiTBYPvYpiKpIC\\_Vaz\\_zxwP956](https://www.youtube.com/playlist?list=PL3JRjVnXiTBYPvYpiKpIC_Vaz_zxwP956)

**Instituto Federal do Sudeste de Minas Gerais - Campus Rio Pomba**

Prof. Dr. Lucas Grassano Lattari - **Curso Completo de Machine Learning**

[https://www.youtube.com/watch?v=p\\_SmODmFRUw&list=PL-t7zzWJWPtzhZtl-bWWHFtCfxtjmBdIW&index=1&t=164s](https://www.youtube.com/watch?v=p_SmODmFRUw&list=PL-t7zzWJWPtzhZtl-bWWHFtCfxtjmBdIW&index=1&t=164s)

Prof. Dr. Lucas Grassano Lattari - **Redes Neurais Artificiais em Python**

[https://www.youtube.com/playlist?list=PL-t7zzWJWPtygNTsgC\\_M8c9a-p5biCjho](https://www.youtube.com/playlist?list=PL-t7zzWJWPtygNTsgC_M8c9a-p5biCjho)